




Lectura fundamental

Contextualización

Módulo: Análisis y Visualización de Datos

Unidad 1



Contenido

- 1 Introducción
- 2 Importancia de la ciencia de datos en el mundo contemporáneo
- 3 Conceptos básicos de análisis y visualización de datos
- 4 Herramientas y tecnologías utilizadas en análisis y visualización
- 5 Conclusiones

1. Introducción

La ciencia de datos ha adquirido una relevancia crucial en el ámbito actual, dado el considerable volumen de datos que se generan y la imperiosa necesidad de extraer información valiosa de ellos. En esta unidad se explica la importancia de la ciencia de datos en diferentes campos, desde empresas hasta gobiernos, resaltando su capacidad para facilitar la toma de decisiones informadas.

Posteriormente, se explican los conceptos fundamentales en el análisis y visualización de datos, incluyendo tipos de variables, medidas descriptivas como media y desviación estándar, y representaciones gráficas comunes, tales como diagramas de dispersión, histogramas y gráficos de líneas. Se busca sentar bases iniciales para la correcta interpretación y comunicación de información contenida en los datos.

Finalmente, se hace un repaso por algunas de las herramientas y tecnologías más utilizadas actualmente en ciencia de datos, diferenciando entre herramientas de análisis como Python, R y SQL, y herramientas de visualización como Tableau, Qlik y librerías de Python como Matplotlib.

En resumen, esta unidad nos ayuda a entender mejor la importancia de la ciencia de datos y sus conceptos centrales, además de ayudarnos a crear bases para futuros análisis más profundos en cualquier área de la ciencia de datos. Puede servir como punto de partida tanto para principiantes como para personas con algo de experiencia que buscan recapitular y expandir sus conocimientos.

2. Importancia de la ciencia de datos en el mundo contemporáneo

La ciencia de datos es una disciplina que ha adquirido una importancia creciente en el mundo contemporáneo debido a su capacidad para transformar la manera en que las empresas, gobiernos y organizaciones en general toman decisiones, resuelven problemas y obtienen información valiosa.

La ciencia de datos desempeña un papel fundamental en la investigación de datos, ya que emplea herramientas, técnicas y tecnologías para otorgar sentido a la información contenida en los datos. En la actualidad, las organizaciones cuentan con grandes cantidades de datos, debido a la creciente cantidad de dispositivos que pueden recopilar y almacenar información de forma automática.

Por ejemplo, los sistemas en línea y los servicios de pago, como los que se utilizan en el comercio electrónico, la atención médica, las finanzas y otras actividades de la vida cotidiana, registran una gran cantidad de datos que pueden estar en forma de texto, audio, videos e imágenes. A continuación, se presentan algunos ejemplos que ilustran la relevancia de la ciencia de datos en el mundo contemporáneo.

Las empresas analizan datos para entender mejor a sus clientes, optimizar sus operaciones, predecir las tendencias del mercado y **tomar decisiones estratégicas**. Por ejemplo, el portal de comercio electrónico de Amazon utiliza datos de comportamiento del cliente para personalizar recomendaciones de productos. La Figura 1 ilustra cómo una empresa de comercio electrónico puede llevar a cabo recomendaciones de productos de dos maneras distintas. En el lado izquierdo, se muestra la recomendación basada en los intereses del usuario, donde se sugieren productos relacionados con las preferencias individuales o pasadas de ese usuario. Por otro lado, en el lado derecho, se muestra la opción de relacionar usuarios que comparten intereses comunes y, a partir de esas similitudes, se pueden recomendar productos a un usuario B, en función de los intereses del usuario A que comparte esas afinidades.




Figura 1. Ejemplo de sistemas de recomendación utilizado por algunas empresas de comercio electrónico

Fuente: elaboración propia

Como aplicación en **marketing digital**, las empresas utilizan datos para segmentar a su audiencia, medir el rendimiento de campañas publicitarias y personalizar mensajes. Plataformas digitales como Facebook, Google Ads e Instagram permiten a los anunciantes llegar a audiencias específicas mediante datos demográficos y de comportamiento. Otras opciones pueden ser Twitter, LinkedIn, YouTube, Snapchat, Pinterest y Amazon Advertising, cada una ofreciendo herramientas de segmentación para optimizar campañas publicitarias. Estas plataformas permiten una personalización efectiva de mensajes publicitarios.

A su vez, la ciencia de datos se aplica en la **investigación médica** para identificar patrones en grandes conjuntos de datos de pacientes. Por ejemplo, en el campo de la genómica, los científicos utilizan datos para descubrir genes relacionados con enfermedades y desarrollar terapias más efectivas.

Es posible observar una evidencia de que las compañías de **transporte y logística** emplean datos para optimizar las rutas, predecir el mantenimiento de vehículos y mejorar la eficiencia en la entrega de paquetes y correspondencia. Uber, por ejemplo, utiliza algoritmos de ciencia de datos para asignar conductores a pasajeros y determinar tarifas dinámicas.

Los **gobiernos** emplean datos para tomar decisiones informadas sobre **políticas públicas**. Por ejemplo, en la pandemia de COVID-19 se utilizaron modelos de datos para predecir la propagación del virus y guiar las medidas de salud pública.

Por otro lado, la ciencia de datos es fundamental en la **detección de fraudes financieros**, la toma de **decisiones de inversión** y la **gestión de riesgos**. Las instituciones financieras utilizan algoritmos para analizar grandes volúmenes de datos y tomar decisiones en tiempo real.

Todos los casos de ejemplo en relación con el uso de la ciencia de datos son posibles mediante cuatro formas fundamentales para examinar los datos. Estos enfoques se resumen en la Figura 2. En la izquierda se describe el método de análisis, mientras que en la derecha se presenta un ejemplo simplificado.

Tipo de análisis	Ejemplo
Descriptivo Se centra en resumir y presentar datos de manera que sea fácil de entender. Su objetivo principal es revelar patrones, tendencias y características fundamentales de los datos.	Si se tiene un conjunto de datos que registra las ventas mensuales de una tienda durante un año, el análisis descriptivo podría involucrar la creación de gráficos y tablas para mostrar cómo las ventas varían a lo largo de las estaciones, los días de la semana o los productos más vendidos.
Diagnóstico Se enfoca en determinar las causas de ciertos eventos o resultados. Ayuda a identificar problemas o anomalías en los datos y a comprender por qué ocurrieron.	Una empresa experimenta una disminución significativa en sus ingresos durante un trimestre. El análisis de diagnóstico podría implicar examinar factores como el comportamiento de los clientes, cambios en la estrategia de marketing o problemas de producción para entender por qué ocurrió esa disminución.
Predictivo Utiliza datos históricos para predecir eventos o resultados futuros. Se basa en algoritmos y modelos estadísticos para hacer estas predicciones.	Podría utilizarse para predecir el riesgo de una persona de desarrollar una enfermedad en función de sus datos médicos y su historial familiar. Esto podría ayudar a tomar medidas preventivas de acuerdo con los factores de riesgo del paciente.
Prescriptivo Va un paso más allá de la predicción, ya que no solo predice resultados futuros, sino que también sugiere acciones o decisiones específicas para optimizar esos resultados.	En el ámbito de la logística, el análisis prescriptivo podría recomendar la ruta más eficiente para entregar productos en función de factores como el tráfico actual, los costos de combustible y las restricciones de tiempo. Esto ayuda a optimizar la distribución de manera proactiva.

Figura 2. Resumen de los principales enfoques del análisis de datos

Fuente: elaboración propia

En síntesis, la ciencia de datos desempeña un papel fundamental en la resolución de problemas, la toma de decisiones, la innovación y el avance en una amplia gama de campos en la sociedad contemporánea. Su importancia seguirá creciendo a medida que la cantidad de datos disponibles continúe aumentando y las organizaciones busquen formas de aprovechar este valioso recurso.

3. Conceptos básicos de análisis y visualización de datos

El análisis y la visualización de datos son dos elementos fundamentales en el ámbito de la ciencia de datos que se utilizan para comprender y comunicar información a través de conjuntos de datos. Por un lado, el análisis de datos se refiere al proceso de examinar, limpiar, transformar y modelar datos con el objetivo de descubrir patrones, tendencias, relaciones y obtener información significativa a partir de ellos. Esto implica utilizar herramientas, técnicas y algoritmos de análisis de datos para obtener una comprensión más profunda de los datos y extraer conocimientos que puedan respaldar la toma de decisiones, la resolución de problemas y la formulación de estrategias. El análisis de datos puede incluir múltiples actividades, tales como el análisis estadístico, el aprendizaje automático, la minería de datos, la exploración de datos y la construcción de modelos predictivos. El propósito final consiste en obtener información valiosa que, además, pueda ser empleada para tomar decisiones efectivas y generar ventajas competitivas.

Por otro lado, la visualización de datos se refiere al proceso de representar gráficamente datos y resultados del análisis de una manera que sea fácilmente comprensible para los seres humanos. Estas utilizan gráficos, tablas, mapas y otros elementos visuales para presentar información de una manera clara y efectiva. A su vez, la visualización de datos desempeña un papel fundamental en la comunicación de hallazgos y resultados a un público diverso. Al presentar datos de manera visual, se facilita la identificación de patrones, la detección de tendencias y la comprensión de relaciones, lo que puede ayudar, junto con otras técnicas y disciplinas, a tomar decisiones informadas y a comunicar información de manera más efectiva.

En síntesis, el análisis de datos se enfoca en la exploración y procesamiento de datos con el fin de obtener información, mientras que la visualización de datos se enfoca en la representación visual de estos datos, con el fin de facilitar su comprensión y comunicación. Los dos elementos son fundamentales en el proceso de trabajo con datos y son empleados en conjunto con el fin de maximizar la capacidad de aprovechar la información contenido en conjuntos de datos.

A continuación, se enuncian algunos de los conceptos básicos en análisis y visualización de datos. Aunque son conceptos que, en un futuro, posiblemente en un curso de Estadística se deban profundizar, se hará una breve definición de estos, ya que son importantes para interpretar y comunicar eficazmente la información contenida en los datos.

Por un lado, los **datos** son hechos o información que se recopila, registra o almacena. Pueden tomar diversas formas, como números, texto, imágenes, sonidos o cualquier otra representación de información. Los datos son la materia prima de la ciencia de datos y se utilizan para obtener información, conocimiento y tomar decisiones.

Por el otro, las **variables** son características, propiedades o atributos que pueden tomar diferentes valores en un estudio o experimento. En un contexto de investigación, una variable es un elemento que se mide o se observa, cuyos valores pueden variar en función de individuos, objetos, eventos o circunstancias. Las variables pueden ser de diferentes tipos, como variables numéricas, categóricas o cualitativas, y se utilizan para estudiar relaciones, patrones y efectos en el análisis de datos. Por ejemplo, en un estudio de psicología, la edad de las personas sería una variable numérica, mientras el género sería una variable categórica.




Figura 3. Tipos de variables

Fuente: elaboración propia

Dentro de las técnicas de estadística descriptiva para la creación de resúmenes gráficos, existen una serie de visualizaciones que continúan siendo ampliamente utilizadas a pesar de los avances en técnicas de visualización y diseño gráfico. Esto se debe, en gran medida, a su sencillez y efectividad en la comunicación de información contenida en los datos. Estos diagramas son el de dispersión, el histograma, diagrama de barras y diagrama circular.

El **diagrama de dispersión** es una representación gráfica que muestra la relación entre dos variables numéricas. Cada punto en el gráfico representa un par de valores para ambas variables, lo que facilita la identificación de patrones, tendencias y correlaciones entre ellas. Como ejemplo, se considera el precio de un conjunto de apartamentos y su área como se muestra en la Figura 4, en la que cada punto representa un apartamento. En el eje horizontal se muestra el área, expresada en metros cuadrados, mientras en el eje vertical los valores del precio de venta, en millones de pesos colombianos (MCOP).




Figura 4. Ejemplo de diagrama de dispersión: Relación entre área y precio de venta de un conjunto de apartamentos

Fuente: elaboración propia

Un histograma es un gráfico que muestra la distribución de frecuencias de una variable numérica continua. Divide los datos en intervalos y muestra cuántos datos caen en cada intervalo. Esto

proporciona información sobre la forma y la dispersión de la distribución (Anderson et al., 2001). Como ejemplo, se podría considerar que se tienen datos de los precios de venta y el área de un conjunto de apartamentos como se muestra en la Figura 5.

El histograma representa la distribución de precios, dividiendo precios en intervalos (por ejemplo, grupos de 100 millones de pesos) en el eje horizontal y mostrando la cantidad de apartamentos en cada intervalo en el eje vertical. Esto permitiría ver si la mayoría de los apartamentos tienen precios similares, o si los apartamentos muy costosos son pocos. En el ejemplo, se puede evidenciar que la mayoría de los apartamentos está entre los 175 y los 375 millones de pesos. En la Figura 5 también se muestra la representación gráfica de las áreas del conjunto de apartamentos.




Figura 5. Ejemplo de histograma: Distribución de los precios de venta y las áreas de los apartamentos

Fuente: elaboración propia

Un **diagrama de barras** es un gráfico que se utiliza para representar datos categóricos o discretos. Cada categoría se representa con una barra cuya altura representa la frecuencia o cantidad asociada a esa categoría (Anderson et al., 2001). Por ejemplo, suponiendo que se desea mostrar el número de apartamentos con determinado número de habitaciones, se puede crear un diagrama como el de la izquierda de la Figura 6. Este diagrama muestra la distribución de apartamentos, de acuerdo con el número de habitaciones, evidenciando que la gran mayoría tiene 3 habitaciones, por ejemplo. Por otro lado, si se quiere ver la distribución de apartamentos en cada una de las zonas de la ciudad, también se puede utilizar un diagrama de barras (derecha, Figura 6). En estos dos ejemplos, se observa que el diagrama de barras es útil para representar distribución de variables numéricas discretas y variables categóricas.




Figura 6. Ejemplo de diagrama de barras: distribución de apartamentos, de acuerdo con el número de habitaciones (izquierda) y de acuerdo con la zona de la ciudad (centro). A la derecha, se muestra un ejemplo de diagrama circular.

Fuente: elaboración propia

El **diagrama de circular**, también conocido como gráfico de pastel, representa datos categóricos o proporcionales como una "torta" dividida en sectores. Cada sector representa una categoría y su tamaño angular es proporcional a la cantidad o porcentaje que representa en el total (Anderson et al., 2001). El ejemplo, en este caso, corresponde a la proporción de apartamentos que cuentan con parqueadero y los que no (Figura 6, derecha). Este gráfico no es adecuado cuando se cuenta con varias categorías, ya que se dificulta un poco comparar las porciones de cada sector.

Algunos conceptos estadísticos básicos, que pueden servir para resumir en forma numérica una variable y que son fundamentales para el análisis de datos, son la media, la mediana, la moda y las medidas de dispersión. A continuación, se especifica cada una:

- La **media**, también conocida como promedio, es el valor obtenido al sumar todos los valores de un conjunto de datos y luego dividir la suma por la cantidad de valores. Es una medida que proporciona el valor promedio de un conjunto de datos (Anderson et al., 2001). Suponiendo que se tiene un conjunto de calificaciones en un examen: 80, 85, 90, 92 y 78. Para calcular la media, se suman estos valores ($80 + 85 + 90 + 92 + 78 = 425$) y luego se dividen por la cantidad de calificaciones (5), lo que daría una media de 85.
- La **mediana** es el valor que se encuentra en el centro de un conjunto de datos cuando los valores se ordenan en orden ascendente o descendente (Anderson et al., 2001). Considerando el conjunto de datos de calificaciones: 80, 85, 90, 92 y 78, al ordenarlos en forma ascendente, la mediana sería el valor central, que es 85. En algunos casos, la media y la mediana pueden coincidir.
- La **moda** es el valor o valores que aparecen con mayor frecuencia en un conjunto de datos. Puede haber una moda (un valor que se repite más que cualquier otro) o múltiples modas si

varios valores tienen la misma frecuencia máxima (Anderson *et al.*, 2001). Por ejemplo, si se tiene el conjunto de datos de calificaciones: 80, 85, 85, 90, 92, 92, 78, la moda sería 85 y 92, ya que ambos valores se repiten dos veces, más que cualquier otro valor en el conjunto.

- La **desviación estándar** es una medida de dispersión que indica cuánto se alejan los valores individuales de la media de un conjunto de datos, es decir, es una medida de la variabilidad en los datos (Anderson *et al.*, 2001). Si se tienen dos conjuntos de datos con la misma media, por ejemplo 30, pero uno tiene desviación estándar de 5 y el otro de 10, tal como se muestra respectivamente en los histogramas de la Figura 7. Se observa que un valor alto de desviación estándar (derecha) indica que los datos varían significativamente de la media, mientras que un valor bajo indica que los datos están más agrupados cerca de la media.




Figura 7. Comparación de dos conjuntos de datos con la misma media (30) y diferentes desviaciones estándar, 5 y 10, respectivamente

Fuente: elaboración propia

- Los **cuantiles** son valores que dividen un conjunto de datos en partes iguales. El cuantil más común es el percentil, que divide los datos en 100 partes iguales. Por ejemplo, el **percentil 25** (cuartil 1, Q1) divide los datos en el 25 % más bajo y el percentil 75 (cuartil 3, Q3) en el 25 % más alto. Como se puede apreciar, los cuantiles son un caso particular de los percentiles: los cuantiles dividen el conjunto de datos ordenados en cuatro partes iguales. El primer cuartil es un valor para el cual al menos el 25 % de los datos son menores o iguales a él. El segundo cuartil, que también es igual a la mediana, corresponde a un valor para el cual al menos el 50 % de los datos son menores o iguales. Por último, el tercer cuartil es un valor para el cual al menos el 75 % de los datos se encuentran por debajo de este (Anderson *et al.*, 2001).
- Un **boxplot**, también conocido como **diagrama de caja y bigotes**, es una representación gráfica que muestra la distribución de un conjunto de datos y proporciona información sobre

la mediana, los cuartiles y los valores atípicos. La caja en el centro del gráfico representa el rango intercuartílico (RIC), con el extremo izquierdo de la caja como el primer cuartil (Q_1) y el extremo derecho como el tercer cuartil (Q_3). La línea en el interior de la caja muestra la mediana. Los bigotes se extienden desde la caja y generalmente tienen una longitud de 1.5 veces el RIC. Puede haber valores atípicos más allá de los bigotes, que se representan como puntos individuales. Los extremos de los bigotes pueden variar en función de la interpretación. El boxplot es útil para visualizar la distribución, identificar valores atípicos y comparar diferentes grupos de datos. En la Figura 8 se ilustran en detalle las partes de un diagrama de caja y bigotes.




Figura 8. Ilustración de un diagrama de caja y bigotes (boxplot) y cada una de sus partes.

Fuente: elaboración propia

Muchas veces, apoyándose en el análisis y la visualización de datos, se va a poder observar la correlación entre variables. Ahora bien, la **correlación** se refiere a la medida de la relación o asociación entre dos variables. Indica si dos variables se mueven juntas y cómo lo hacen. Esta correlación puede ser **positiva**, significa que tienden a aumentar o disminuir juntas, si una variable aumenta, la otra tiende a aumentar y, si una variable disminuye, la otra tiende a disminuir; **negativa**, significa que una tiende a aumentar cuando la otra disminuye y, viceversa; o **nula**, significa que no hay relación aparente entre las dos variables, en otras palabras, los cambios en una variable no están asociados de manera consistente con cambios en la otra.

- El **heatmap**, también conocido como **mapa de calor**, es una representación gráfica que utiliza colores para visualizar la magnitud de los valores en una matriz. En el contexto de análisis de datos, se emplea para mostrar la intensidad o la relación entre múltiples variables en una tabla. En el caso de un conjunto de datos con interacciones entre variables, el mapa de calor se vuelve útil al resaltar patrones, tendencias o correlaciones entre diferentes variables. Los colores representan los valores numéricos, donde tonalidades más intensas denotan valores altos y tonalidades más suaves indican valores bajos. Esta representación visual facilita la identificación

de áreas de interés, destacando relaciones significativas dentro de conjuntos de datos complejos, lo que lo convierte en una herramienta valiosa para la toma de decisiones y el análisis en diversas áreas.

Como ejemplo se puede considerar el mapa de calor de la Figura 9, en el que se muestra la relación entre seis variables diferentes. Este diagrama muestra si existe y de qué tipo es la correlación entre las diferentes variables. Por ejemplo, COLCAP tiene correlación negativa con todas las demás variables, mientras que WTI tiene una correlación positiva con BRENT y TI_COL, mientras que con IPC_COL, aunque positiva, es una correlación débil. Como se puede observar, los colores están de acuerdo con los valores del coeficiente de correlación.




Figura 9. Ilustración de un mapa de calor (heatmap)

Fuente: elaboración propia

- Los **gráficos de línea** son una forma común y efectiva de representar la evolución o tendencia de datos a lo largo de un eje temporal o secuencial. Este tipo de gráfico traza puntos de datos conectados por líneas, lo que permite visualizar la variación y relaciones entre diferentes valores en función de la progresión temporal u otro tipo de secuencia. Generalmente, en el eje horizontal se sitúa el tiempo o la secuencia, mientras que en el eje vertical se representa la magnitud o la medida de los datos. Los gráficos de línea son útiles para analizar tendencias,

cambios y patrones a lo largo del tiempo, facilitando la identificación de picos, valles o fluctuaciones en los datos. Además, estos gráficos son comunes en áreas como análisis financiero, ciencia, economía y cualquier otro campo en el que sea crucial comprender cómo ciertas variables cambian con el tiempo o a lo largo de una secuencia determinada.

La Figura 10 es un ejemplo de un gráfico de línea en el que se muestra el comportamiento de las ventas de dos productos en los últimos 10 años (2013 al 2023). Además, se muestra el comportamiento de las ventas a lo largo del tiempo para cada producto, se puede hacer una comparación del comportamiento de ambos productos a lo largo de los 10 años.




Figura 10. Gráfico de línea: comportamiento de las ventas en los últimos 10 años de los dos principales productos de una empresa

Fuente: elaboración propia

Existen otros tipos de gráficos menos utilizados, dentro de los que destacan los diagramas de árbol, de red y los gráficos de burbuja. Los primeros son útiles para mostrar jerarquías y relaciones de desglose, estos representan datos en forma de ramas y subramas, lo que facilita la comprensión de la estructura y las relaciones jerárquicas entre los elementos. Los segundos se utilizan para representar relaciones complejas entre diferentes entidades o nodos; son eficaces para visualizar redes sociales, conexiones

de internet, relaciones comerciales y cualquier conjunto de datos con interacciones complejas y los terceros permiten representar tres variables en un solo gráfico, utilizan el tamaño y la posición de las burbujas para mostrar la relación entre las variables, lo que puede revelar patrones interesantes o relaciones entre los datos.

4. Herramientas y tecnologías utilizadas en análisis y visualización

Las herramientas y tecnologías para el análisis y la visualización de datos son recursos, programas informáticos y enfoques tecnológicos utilizados para examinar, interpretar, procesar y presentar información derivada de un conjunto de datos. Estas herramientas pueden variar desde *software* especializado hasta lenguajes de programación, plataformas de visualización y entornos de desarrollo. Su objetivo principal es permitir a los usuarios explorar datos, identificar patrones, tendencias o relaciones significativas, así como representar esta información visualmente para una comprensión más clara y eficaz. En esta sección se presentarán algunas de las herramientas tecnológicas a disposición para el análisis y la visualización de datos. La selección de las herramientas adecuadas se basará en las necesidades particulares, el tipo de información que se encuentre almacenando y el nivel de aptitudes técnicas disponibles.

4.1. Herramientas de análisis de datos

Las herramientas de análisis de datos están diseñadas específicamente para organizar, manipular y analizar datos provenientes de diversas fuentes. Estas herramientas pueden llevar a cabo una amplia gama de tareas, como limpiar datos, filtrarlos, clasificarlos, agruparlos, resumirlos y realizar cálculos analíticos. Ejemplos de estas herramientas incluyen Excel, Google Sheets, SQL, NoSQL, Python, R y SPSS. A pesar de que existen muchas otras, estas son las más representativas y podrían ser el punto de partida para explorar otras.

- **Microsoft Excel:** es ampliamente reconocido por su funcionalidad de hoja de cálculo, es una herramienta muy popular para análisis de datos sencillos y visualizaciones. Permite importar, transformar y analizar conjuntos de datos mediante fórmulas, tablas dinámicas y gráficos. Aunque está limitado a conjuntos de datos de tamaño pequeño a mediano, Excel sigue siendo uno de los principales activos para el análisis de datos en entornos empresariales por su amplia adopción y facilidad de uso.

- **Google Sheets:** es una hoja de cálculo en la nube que permite analizar y visualizar datos de forma colaborativa. Cuenta con funciones y fórmulas integradas para transformar datos, así como la capacidad de crear gráficos y conectarse a otras herramientas de Google. Es una opción ágil para equipos pequeños que necesiten hacer análisis de datos básico desde cualquier lugar con acceso a internet.
- **Python:** es un lenguaje de programación versátil para análisis y visualización de datos. Cuenta con librerías especializadas como Pandas, NumPy y Matplotlib, que permiten cargar, procesar, analizar y visualizar todo tipo de datos de forma simple y con pocas líneas de código. La capacidad de automatizar flujos de trabajo, integración con todas las fuentes de datos y opciones de despliegue web lo convierten en una de las principales herramientas para científicos de datos y analistas que buscan flexibilidad y productividad en sus proyectos de análisis de datos.
- **R:** es un lenguaje de programación especializado en estadística, modelado y análisis de datos. Cuenta con una extensa colección de paquetes que cubren una amplia gama de técnicas analíticas, de *machine learning* y de visualización. R permite cargar, transformar y modelar todo tipo de datos, así como generar visualizaciones estáticas y dinámicas para comunicar *insights*. Su enfoque en análisis cuantitativo, comunidad activa y *software* de código abierto lo convierten en una de las principales herramientas para estadísticos, analistas de datos y científicos de datos.
- **SPSS (Statistical Package for the Social Sciences):** es una herramienta de análisis estadístico que permite a analistas y científicos de datos realizar análisis exploratorio, descriptivo y predictivo sobre conjuntos de datos. Ofrece una interfaz gráfica de usuario que facilita la realización de pruebas estadísticas, la creación de gráficos y visualizaciones, así como el desarrollo de modelos predictivos sin necesidad de programar. Entre sus características, se encuentran el procesamiento de grandes volúmenes de datos, procedimientos automáticos de selección de modelos y una integración con Python y R para mayor flexibilidad. SPSS está ampliamente adoptado en investigación académica y análisis estadístico en empresas.
- **SQL (Structured Query Language):** es un lenguaje fundamental para almacenar y manipular información en bases de datos relacionales, las cuales son sistemas de almacenamiento organizados en tablas para gestionar información mediante relaciones definidas. Permite filtrar, ordenar, agrupar y combinar datos de diferentes tablas mediante distintas cláusulas y funciones. Sus capacidades de manipulación de datos relacionales lo convierten en una pieza fundamental para el análisis y la visualización de datos, sentando las bases para herramientas más avanzadas.

- **NoSQL:** estas bases de datos no relacionales son sistemas de almacenamiento de datos flexibles que no requieren un esquema fijo como las bases de datos relacionales, como MongoDB y Cassandra, están diseñadas para gestionar grandes volúmenes de **datos no estructurados** o semiestructurados. A diferencia de las bases de datos relacionales, NoSQL prioriza escalabilidad, rendimiento y flexibilidad en los modelos de datos.



Datos estructurados

Datos organizados de manera predefinida y con un formato específico, como en las bases de datos relacionales. Se presentan en tablas con filas y columnas, siguiendo un esquema establecido.



Datos no estructurados

Datos que carecen de un formato fijo y no siguen un esquema predefinido. Pueden incluir texto libre, imágenes, audio y otros tipos de información sin una organización específica.

4.2. Herramientas de análisis de datos

Para el caso específico de visualización de datos, estas herramientas son aplicaciones de *software* que le ayudan a presentar y comunicar datos en forma visual, como cuadros, gráficos, mapas, paneles e infografías, estas son útiles para explorar, comprender y compartir información de datos de manera más efectiva y eficiente. Algunos ejemplos representativos de estas herramientas son Tableau, Power BI, Google Data Studio, Qlik y D3.js. En este grupo de herramientas de visualización, vale la pena mencionar que Python y R también cuentan con librerías especializadas para visualización de datos.

Al igual que las herramientas para el análisis de datos, dependiendo de su audiencia y su propósito, puede elegir la herramienta de visualización que mejor transmita su mensaje e historia.

- **Tableau:** es una herramienta de inteligencia de negocios que permite el análisis y la visualización interactiva de datos sin necesidad de programar. Cuenta con una interfaz de “arrastrar y soltar” que facilita la conexión con distintas fuentes de datos, el procesamiento y la creación de tableros de control (*dashboard*) con gráficos dinámicos e indicadores clave de rendimiento. Tableau se

destaca por su capacidad de generar visualizaciones dinámicas e interactivas a partir de múltiples fuentes de datos tanto locales como en la nube. Tableau facilita la creación de visualizaciones efectivas al proporcionar diseños y paletas predefinidas que se ajustan a estándares recomendados, así como mediante el impulso de buenas prácticas de diseño visual como eliminar elementos innecesarios, resaltar los puntos clave, alinear componentes y mantener una adecuada relación entre datos y elementos gráficos.

- **Power BI:** es una plataforma de inteligencia empresarial (BI) desarrollada por Microsoft que ofrece un conjunto de herramientas no solo para visualización de datos, sino también para el análisis de datos y generación de informes. Permite a los usuarios conectar múltiples fuentes de datos, transformar y modelar información, así como crear visualizaciones interactivas como gráficos, tablas y paneles para obtener información útil a partir de conjuntos de datos. Es ampliamente utilizada para la toma de decisiones fundamentadas, ya que ofrece capacidades para explorar, analizar y compartir información en tiempo real, adaptándose a las necesidades de empresas de distintos tamaños y sectores. La plataforma cuenta con diversas versiones que van desde aplicaciones de escritorio hasta soluciones en la nube, facilitando el acceso a datos, generación de informes y colaboración entre equipos.
- **Google Data Studio:** es una herramienta de visualización de datos creada por Google que permite a los usuarios generar informes interactivos y personalizados a partir de una amplia gama de fuentes de datos. Esta plataforma ofrece una interfaz intuitiva y fácil de usar que permite a los usuarios crear visualizaciones de datos personalizadas, como gráficos, tablas, mapas y paneles, para comunicar información de manera efectiva. Entre las principales características se encuentran la capacidad para conectar datos de diversas fuentes, como Google Analytics, Google Ads, bases de datos SQL, hojas de cálculo de Google Sheets, entre otros, y transformarlos en informes visuales y dinámicos. Google Data Studio permite la colaboración en tiempo real, facilita la creación de informes interactivos y la presentación de datos de manera clara y comprensible.
- **Qlik:** es una empresa líder en soluciones de análisis y *business intelligence* que ofrece herramientas para la creación de visualizaciones interactivas y dinámicas. Qlik proporciona una plataforma de visualización de datos que permite a los usuarios crear cuadros de mando interactivos, gráficos, tablas y otros elementos visuales. Estas visualizaciones pueden ser personalizadas y adaptadas para mostrar tendencias, relaciones y patrones ocultos dentro de conjuntos de datos extensos y diversos. Además, la fortaleza de Qlik radica en su capacidad

para asociar datos automáticamente, descubriendo conexiones entre conjuntos de datos aparentemente no relacionados. Esto facilita una comprensión más amplia y profunda de la información, permitiendo a los usuarios realizar análisis detallados y tomar decisiones informadas.

Como se mencionó anteriormente, existen librerías especializadas en visualización de datos para los lenguajes de programación JavaScript, Python y R. Aunque estas soluciones son considerablemente más versátiles que herramientas como Tableau, Power BI y Qlik, requiere más tiempo y presenta cierto nivel de complejidad, pero dominar su uso definitivamente valdrá la pena.

En JavaScript, se cuenta con **D3.js** (*Data Driven Documents*), que es una potente biblioteca que permite crear visualizaciones interactivas y dinámicas en páginas web. Se enfoca en manipular y representar datos usando estándares web como [HTML](#), [XML](#), [SVG](#) y [CSS](#).



HTML

(*Hypertext Markup Language*): Lenguaje de marcado utilizado para la creación y estructuración de contenido en la web. Define la estructura de una página web mediante etiquetas que indican la función de cada elemento.



CSS

(*Cascading Style Sheets*): Lenguaje de estilo utilizado para describir la presentación de un documento HTML. Permite controlar el diseño, el formato y la apariencia de los elementos en una página web, facilitando la separación entre contenido y diseño.



XML

(*Extensible Markup Language*): Lenguaje de marcado diseñado para almacenar y transportar datos. Utiliza etiquetas personalizadas para definir la estructura y el significado de la información. XML es versátil y se utiliza comúnmente para intercambiar datos entre sistemas heterogéneos y para representar documentos estructurados.



SVG (*Scalable Vector Graphics*): Formato de archivo basado en XML utilizado para representar gráficos vectoriales bidimensionales. Es particularmente útil para imágenes escalables y gráficos interactivos en la web.

En Python, se cuenta con **Matplotlib**, una popular biblioteca de trazado que proporciona una amplia gama de gráficos estáticos y básicos. Ofrece una sintaxis simple para crear gráficos de alta calidad para análisis exploratorio y presentaciones. **Seaborn** se basa en Matplotlib y ofrece una interfaz más fácil para crear visualizaciones estadísticas más complejas. Está especialmente diseñada para mostrar relaciones estadísticas en conjuntos de datos y gráficos más avanzados con menor código. Finalmente, **Plotly** es una librería que proporciona visualizaciones interactivas y dinámicas, ofrece una gama de gráficos estáticos y animados con capacidades de interactividad, ideal para presentaciones y aplicaciones web.

En R, **ggplot2** es una librería que ofrece una gramática de gráficos para crear visualizaciones, se basa en la filosofía de capas y permite a los usuarios construir gráficos complejos a partir de componentes más simples. Al igual que en Python, Plotly en R ofrece capacidades para crear visualizaciones interactivas. Es particularmente útil para la creación de gráficos dinámicos y mapas interactivos en aplicaciones web.

5. Conclusiones

La ciencia de datos ha cobrado una enorme relevancia en el mundo actual debido a los grandes volúmenes de datos disponibles y la necesidad de extraer valor de ellos. Las organizaciones recurren a la ciencia de datos para tomar mejores decisiones informadas, resolver problemas, innovar y obtener ventajas competitivas en diversas áreas.

El análisis y visualización de datos son componentes centrales de la ciencia de datos. El análisis implica examinar y modelar datos para descubrir patrones y tendencias mediante técnicas como el análisis estadístico, el aprendizaje automático y la minería de datos. La visualización convierte esos hallazgos en representaciones gráficas comprensibles que facilitan la comunicación y la toma de decisiones.

Entre los conceptos básicos se encuentran tipos de variables, medidas descriptivas y gráficos como diagramas de dispersión, histogramas y mapas de calor.

Existe una amplia variedad de herramientas y tecnologías para el análisis y visualización de datos, desde software especializado como Tableau y Power BI, hasta lenguajes de programación como Python, R y JavaScript. La selección de las herramientas depende de las necesidades y habilidades técnicas. En conjunto, estas permiten explotar al máximo la información en los datos para generar conocimiento de valor.

Referencias

Anderson, D. R., Sweeney, D. J., Williams, T. A., (M. D. Hano Roa, Trad.). (2001). *Estadística para administración y economía*. Cengage learning.



Información técnica

Módulo: Análisis y Visualización de Datos

Unidad 1: Contextualización

Autor: David Bacca Morales

Asesora Pedagógica: Jessica Katherin Pinzón Arias

Diseñador Gráfico: Laura Daniela Ortiz

*Este material pertenece al Politécnico Grancolombiano.
Prohibida su reproducción total o parcial.*