




Lectura fundamental

Análisis de datos y visualización

Módulo: Análisis y Visualización de Datos

Unidad 2



Contenido

- 1 Introducción
- 2 Tipos de datos y su aplicación desde las humanidades hasta la ingeniería
- 3 Herramientas para el análisis y transformación de datos
- 4 Principios de diseño de visualización para comunicar eficazmente información relevante
- 5 Conclusiones

1. Introducción

En la era de los datos, la capacidad de analizar información y comunicar hallazgos de forma efectiva es más importante que nunca. En esta unidad se exploran conceptos clave relacionados con el análisis y la visualización de datos desde una perspectiva multidisciplinaria.

Se comienza analizando la diversidad de tipos de datos que existen, desde cifras cuantitativas hasta material multimedia y textual. Se presentan ejemplos concretos de cómo estos datos se aplican en campos que van desde las humanidades y las ciencias sociales, hasta los negocios y la ingeniería.

Luego, se exploran algunas de las principales herramientas utilizadas actualmente para la transformación y el análisis de datos en distintas disciplinas. Desde lenguajes de programación como Python y R, hasta plataformas de inteligencia de negocios y *big data*.

Por último, se revisarán algunos principios fundamentales de cómo diseñar visualizaciones de datos efectivas, cómo enfocarse en lo importante, mantener la simplicidad, evitar sesgos, facilitar comparaciones y validar la efectividad con los usuarios.

Al finalizar esta unidad, se contará con las bases para comprender el amplio panorama de tipos de datos, herramientas analíticas y buenas prácticas en visualización de información. En este proceso de revisión de conceptos se destaca la naturaleza multidisciplinaria del trabajo con datos en la actualidad.

2. Tipos de datos y su aplicación desde las humanidades hasta la ingeniería

Como se mencionó previamente, los datos son esenciales en la era de la información. Su recolección, procesamiento, análisis y visualización permiten extraer *insights*, generar conocimiento y dar un sustento a la toma de decisiones. Existen diversos tipos de datos, cada uno con características distintivas. Comprender estas tipologías en profundidad es crucial para sacar el máximo provecho a los datos. La Tabla 1 resume los tipos de datos más utilizados, con algunos ejemplos simples y una breve descripción.



[insights]

Se refiere a una observación o comprensión profunda que se obtiene al analizar conjuntos de datos. Estos insights son descubrimientos significativos o patrones que pueden llevar a una comprensión más completa de un problema o situación.

Tabla 1. Descripción, ejemplo y escalas de diferentes tipos de datos

Tipo de datos	Ejemplos	Escala	Descripción
Cuantitativo/numérico continuo	1.5, 7.54, 93, 1.2×10^5	Continua	Valores numéricos arbitrarios. Pueden ser números enteros, números racionales o números reales.
Cuantitativo/numérico discreto	1, 2, 3, 4	Discreta	Números en unidades discretas. Estos son más comunes, pero no necesariamente números enteros. Por ejemplo, los números 0.5, 1.0, 1.5 también podrían tratarse como discretos si no pueden existir valores intermedios en el conjunto de datos dado.
Cualitativo/categorico sin orden	Automóvil, autobús, bicicleta, motocicleta	Discreto	Categorías sin orden. Se trata de categorías discretas y únicas que no tienen un orden inherente. Estas variables también se llaman factores.
Cualitativo/categorico ordenado	Bueno, muy bueno, excelente	Discreto	Categorías con orden. Se trata de categorías discretas y únicas con un orden inherente. Por ejemplo, "muy bueno" siempre se sitúa entre "bueno" y "excelente". Estas variables también se denominan factores ordenados.

Tipo de datos	Ejemplos	Escala	Descripción
Fecha u hora	13 ene. 1985, 21:15	Continuo o discreto	Días, horas o años específicos. También fechas genéricas, como el 20 de julio o el 13 de enero (sin año).
Texto	El cliente asegura que nunca recibió respuesta a la petición.	Ninguno o discreto	Texto de formato libre. Puede tratarse como categórico si es necesario.
Geoespacial	Latitud: 4.7445448	Continuo o discreto	Describen ubicaciones geográficas. Incluyen coordenadas (latitud/ longitud), direcciones, códigos postales. Permiten mapeo y análisis de distribución espacial.
Multimedia	Imágenes, audio, video	NA	Aunque los datos multimedia pueden ser procesados y analizados en cuanto a píxeles, ondas de sonido, fotogramas o cualquier otra unidad técnica, su interpretación y análisis frecuentemente implican enfoques cualitativos o técnicas específicas de procesamiento digital para comprender y manipular la información contenida en estos formatos.

Fuente: elaboración propia

Aplicaciones en humanidades

En las humanidades se trabaja con una amplia gama de datos, algunos de los cuales son no estructurados y otros estructurados. Los datos no estructurados son predominantemente de naturaleza cualitativa, como textos literarios, historiográficos, filosóficos o incluso entrevistas y transcripciones de discursos. El análisis cualitativo de estos textos implica identificar patrones, temas, opiniones, emociones y tendencias, a través de métodos como el análisis de contenido, la minería de texto o el procesamiento del lenguaje natural (NLP). Algunas de estas técnicas se abordarán posteriormente.

Por otro lado, existen datos estructurados en las humanidades que pueden incluir información cuantitativa, como fechas de eventos históricos, datos demográficos, categorías socioeconómicas, datos geoespaciales, entre otros. Estos datos a menudo se pueden organizar en formatos tabulares o bases de datos, lo que permite un análisis más cuantitativo a través de métodos estadísticos y análisis de datos.

La combinación de análisis cualitativos y cuantitativos en las humanidades es cada vez más común, ya que la integración de ambas metodologías puede proporcionar una comprensión más completa y profunda de diversos temas y disciplinas dentro de este campo.

Aplicaciones en ciencias sociales

Las ciencias sociales utilizan una combinación de datos cualitativos y cuantitativos para comprender aspectos diversos de la sociedad. Las encuestas son una herramienta fundamental para recopilar datos cuantitativos en campos como sociología, psicología, ciencias políticas y economía. Estos datos pueden ser categóricos, proporcionando información sobre preferencias, opiniones, comportamientos y demografía de una población.

El análisis cualitativo se realiza a menudo en datos provenientes de entrevistas, grupos focales, análisis de contenido, observaciones etnográficas y otro tipo de material textual. Este análisis cualitativo permite comprender opiniones, narrativas, percepciones y complejidades que a menudo no se capturan mediante métodos puramente cuantitativos.

Además, las ciencias sociales también emplean datos numéricos para analizar indicadores económicos, sociales y de salud. Estos pueden ser tanto datos primarios como secundarios, abarcando aspectos como PIB, tasas de desempleo, niveles de educación, estadísticas de salud, entre otros.

Por su parte, el mapeo geoespacial, mediante herramientas de GIS (Sistemas de Información Geográfica), es otra técnica utilizada para visualizar y comprender la distribución espacial de fenómenos sociales, económicos y culturales. Este tipo de representación permite identificar patrones y relaciones espaciales que podrían no ser evidentes en otros tipos de análisis.

Aplicaciones en negocios

En el ámbito empresarial, los datos son fundamentales para tomar decisiones informadas y estratégicas. Los datos numéricos, como las ventas, costos, precios, datos financieros y de producción, son la base de la inteligencia de negocios. Estos datos, cuando se analizan en conjunto, pueden ofrecer información valiosa para comprender el rendimiento de la empresa, identificar tendencias y oportunidades, y optimizar la toma de decisiones.

El análisis de series de tiempo es crucial para pronosticar la demanda futura, identificar patrones estacionales o cíclicos y anticipar cambios en el mercado. Estos análisis ayudan a ajustar estrategias de producción, inventario y *marketing*.

Los datos de clientes, por su parte, son fundamentales para la segmentación del mercado y la personalización de estrategias de *marketing*. Al analizar el comportamiento, preferencias y características de los clientes, las empresas pueden adaptar sus productos y servicios, y crear campañas de marketing más efectivas y focalizadas.

Además, el análisis de datos provenientes de redes sociales y otras fuentes de texto en línea brinda información valiosa sobre la reputación de la marca, las opiniones de los clientes y las tendencias del mercado. Este análisis permite a las empresas comprender mejor la percepción de la marca, identificar problemas potenciales y mejorar su relación con los clientes.

Aplicaciones en ciencia e ingeniería

En ciencia e ingeniería, la generación de datos es masiva y hay una variedad de tipos. Los datos numéricos provienen de experimentos, observaciones y simulaciones. Por medio del análisis estadístico se pueden comprender y sacar conclusiones de estos datos, permitiendo identificar patrones, relaciones y significados dentro de conjuntos de información complejos. Algunas disciplinas se apoyan en la ingeniería para realizar trabajos basados en ciencia de datos, sin embargo, en la actualidad es creciente el uso directo de las técnicas en diferentes disciplinas.

Los datos multimedia, como imágenes, video y audio, son cruciales en áreas como la biomedicina. La radiología, por ejemplo, proporciona datos visuales que son analizados para diagnósticos, tratamiento y seguimiento de enfermedades. En ingeniería, el análisis de imágenes y video se utiliza para diversas

aplicaciones, desde el reconocimiento de objetos hasta el monitoreo de infraestructuras.

Los sensores desempeñan un papel fundamental en la generación de datos continuos en tiempo real. Estos datos provienen de diferentes fuentes, como sensores climáticos, dispositivos médicos, sensores industriales, entre otros. El análisis de datos provenientes de sensores es clave para la toma de decisiones rápidas, la detección temprana de problemas y la optimización de procesos.

Además, el texto de publicaciones científicas y técnicas proporciona un contexto fundamental para la comprensión de los avances en la investigación. El análisis de este tipo de datos textuales a menudo implica técnicas de minería de texto y procesamiento del lenguaje natural para identificar información relevante, tendencias, conexiones entre estudios y avances en el campo científico o técnico.

En general, en ciencia e ingeniería, la diversidad de datos generados abarca desde datos numéricos complejos hasta información multimedia y textual, lo que requiere una variedad de enfoques analíticos para extraer conocimiento significativo y aplicable.

3. Herramientas para el análisis y transformación de datos

El análisis de datos implica examinar y derivar información significativa de conjuntos de datos, mientras que la transformación de datos se centra en modificar la estructura o el contenido de los datos para prepararlos para el análisis o para cumplir con requisitos específicos. Estas dos actividades están estrechamente relacionadas y son esenciales para obtener información valiosa a partir de datos brutos.

Como se explicó anteriormente, los lenguajes de programación como Python y R se destacan en el ámbito de la ciencia e ingeniería. En estos lenguajes, una biblioteca (también conocida como librería en R) es un conjunto de funciones, herramientas y rutinas predefinidas que facilitan tareas específicas. Estas bibliotecas son desarrolladas por la comunidad o por organizaciones y se utilizan para extender las capacidades de los lenguajes base.

En el análisis numérico y estadístico, Python se destaca con bibliotecas como NumPy para cálculos numéricos y SciPy para algoritmos científicos, como integración numérica, métodos de optimización, entre otros. Para la manipulación eficiente de datos, Pandas es ampliamente utilizado. La visualización de datos se logra con matplotlib y seaborn. Dos paquetes utilizados en R para la manipulación y visualización de datos son dplyr y ggplot2, respectivamente (Ministerio de Tecnologías de la Información y las Comunicaciones [MINTIC], 2018).

A continuación, se mostrará un ejemplo sencillo del uso de R para hacer algunas tareas de manipulación de un conjunto de datos, utilizando el paquete dplyr. Este ejemplo se realizará utilizando

una base de datos llamada “iris”, que es un conjunto de datos clásico en estadística y aprendizaje automático, está disponible en R y se utiliza como muestra para prácticas de clasificación y análisis de datos debido a su simplicidad y claridad. Este conjunto de datos contiene mediciones de cuatro características (longitud del sépalo, ancho del sépalo, longitud del pétalo y ancho del pétalo) de tres especies de flores de iris (setosa, versicolor y virginica).

Primero se carga la librería dplyr y el conjunto de datos “iris”:

```
library(dplyr)
```

```
data("iris")
```

Utilizando el comando `head(iris)` obtenemos las primeras seis filas del conjunto de datos:

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1          3.5          1.4          0.2 setosa
## 2          4.9          3.0          1.4          0.2 setosa
## 3          4.7          3.2          1.3          0.2 setosa
## 4          4.6          3.1          1.5          0.2 setosa
## 5          5.0          3.6          1.4          0.2 setosa
## 6          5.4          3.9          1.7          0.4 setosa
```

Para hacerse una mejor idea de las variables, se puede utilizar el comando `summary(iris)`, que muestra un resumen de seis números en el caso de las variables numéricas y los valores que toman las variables cualitativas:

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width
## Min. :4.300 Min. :2.000 Min. :1.000 Min. :0.100
## 1st Qu.:5.100 1st Qu.:2.800 1st Qu.:1.600 1st Qu.:0.300
## Median :5.800 Median :3.000 Median :4.350 Median :1.300
## Mean :5.843 Mean :3.057 Mean :3.758 Mean :1.199
## 3rd Qu.:6.400 3rd Qu.:3.300 3rd Qu.:5.100 3rd Qu.:1.800
```

```
## Max. :7.900 Max. :4.400 Max. :6.900 Max. :2.500
## Species
## setosa :50
## versicolor:50
## virginica :50
```

Ahora, se muestra un ejemplo donde se crea un nuevo conjunto de datos a partir de “iris”, que contiene únicamente registros de la especie versicolor con tamaño de pétalo mayor a 4.8 cm.

- - Filtro 1: la variable ‘Species’ debe ser igual a ‘versicolor’.
- - Filtro 2: la variable ‘Petal.Length’ debe ser mayor a 4.8.

El código sería el siguiente:

```
versicolorGrande <- iris %>%
  filter(Species == "versicolor") %>%
  filter(Petal.Length > 4.8)
versicolorGrande
```

Y el resultado, que sería el nuevo conjunto de datos llamado versicolorGrande, quedaría así

##	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
## 1	6.9	3.1	4.9	1.5	versicolor
## 2	6.3	2.5	4.9	1.5	versicolor
## 3	6.7	3.0	5.0	1.7	versicolor
## 4	6.0	2.7	5.1	1.6	versicolor

Otro ejemplo podría ser un resumen de las longitudes promedio de los pétalos de cada una de las especies. Para esto, se puede utilizar el código:

```
LongPetalosPromedio <- iris %>%
  group_by(Species) %>%
  summarise(Petal.Length.Promedio = mean(Petal.Length))
```

LongPetalosPromedio

Con lo cual se obtiene el siguiente resumen:

```
## Species Petal.Length.Promedio
## <fct>          <dbl>
## 1 setosa          1.46
## 2 versicolor      4.26
## 3 virginica       5.55
```

Existen compiladores en línea donde se puede probar códigos de diferentes lenguajes. Para el caso de R, una opción es <https://rdr.io/snippets/>. A continuación, se presenta el código completo que se puede probar en este sitio.

```
library(dplyr)
data("iris")
head(iris)
summary(iris)
versicolorGrande <- iris %>%
  filter(Species == "versicolor") %>%
  filter(Petal.Length > 4.8)

versicolorGrande
LongPetalosPromedio <- iris %>%
```

```
group_by(Species) %>%
```

```
summarise(Petal.Length.Promedio = mean(Petal.Length))
```

LongPetalosPromedio

Alonso Cifuentes (2022) presenta una primera aproximación al paquete *dplyr* que permite manipular rápidamente bases de datos en R.

En el ámbito de las ciencias sociales y humanidades, tanto Python como R son herramientas versátiles para análisis de texto, por ejemplo, identificar la postura del escritor frente a un tema, con paquetes como NLTK y gensim en Python; y tidytext y tm en R. Para el análisis de datos geográficos, se recurre a geopandas, shapely y matplotlib en Python; y sf, ggplot2 y leaflet en R.

El análisis de redes sociales se puede llevar a cabo con herramientas como networkx y Gephi, por ejemplo, identificando comunidades y analizando la difusión de información en estas redes; mientras que el *web scraping* se realiza con BeautifulSoup y Selenium en Python. SPSS es un software estadístico que se utiliza comúnmente en ciencias sociales para realizar análisis estadísticos, pruebas de hipótesis y manipulación de datos. NVivo, QDA Miner y Atlas.ti son herramientas de análisis cualitativo para ciencias sociales y humanidades.

En el ámbito de negocios y data analytics, Excel sigue siendo muy utilizado debido a su facilidad de uso. Además, las suites de Business Intelligence como Tableau, Power BI y Qlik permiten análisis visual y la creación de *dashboards* interactivos. Python y R también desempeñan un papel crucial en esta área, siendo utilizados para análisis estadístico avanzado y *machine learning*.

Las bases de datos con estructura SQL se gestionan con sistemas como PostgreSQL, MySQL y MariaDB, y las bases NoSQL se manejan con programas como MongoDB. Estos aplicativos son fundamentales para almacenar, extraer, transformar y consultar grandes volúmenes de datos de manera eficiente.

Informatica, Talend y Pentaho son suites de *software* que proporcionan herramientas y entornos para gestionar, transformar y analizar datos en entornos empresariales. Estas permiten automatizar flujos de trabajo para la preparación de datos, asegurando la coherencia y calidad de la información.

Para manejar grandes volúmenes de datos no estructurados y semiestructurados, plataformas como Hadoop y Spark son esenciales. Estas tecnologías de *big data* permiten escalar el procesamiento distribuido de datos, es decir, se emplean dentro de un enfoque en el que los datos se almacenan y gestionan en múltiples nodos o ubicaciones físicas que están interconectados, brindando soluciones eficientes para análisis en entornos con grandes cantidades de información.

La combinación adecuada de bases de datos, plataformas de visualización y herramientas ETL (en inglés *"Extract, Transform, Load"*) y lenguajes de programación, depende de la disciplina, el tipo de datos y los requerimientos analíticos específicos, subrayando la importancia de adaptar las herramientas a las necesidades particulares de cada dominio. La intención de esta sección es mencionar algunas de las herramientas más utilizadas y los enfoques de cada una de ellas. Sin lugar a duda, existen muchas más herramientas para los propósitos y disciplinas mencionados, este es un punto de partida para que el lector pueda ampliar el conocimiento sobre estas.

4. Principios de diseño de visualización para comunicar eficazmente información relevante

La efectividad de una visualización de datos para comunicar eficazmente información relevante depende en gran medida de cómo se aplican los principios fundamentales de diseño. A continuación, se explorarán estos principios. En la Figura 1 se agrupan los principios fundamentales de diseño en visualización, teniendo en cuenta la función que cumplen.




Figura 1. Principios de diseño de visualización agrupados por funciones

Fuente: elaboración propia

Enfocarse en lo importante

En el diseño de visualizaciones de datos, es fundamental centrarse en lo relevante. Este principio implica resaltar información crucial y tendencias para dirigir la atención del espectador (Wilke, 2019). Por ejemplo, al analizar un gráfico de barras que compara las ventas del cuarto trimestre de 2023 con las de los trimestres anteriores, se busca que el interés se concentre en la barra que representa dicho trimestre, como se ilustra en la Figura 2.

Ventas en cada trimestre del 2023 en millones de pesos




Figura 2. Aplicación del principio de enfocarse en lo importante haciendo uso del color para destacar un elemento

Fuente: elaboración propia

Mantenerlo simple

El principio de mantenerlo simple es fundamental: utilizar gráficos sencillos, ya que facilita la interpretación rápida de la información (Wilke, 2019). Como un ejemplo de lo que no se debería

hacer, se puede considerar el gráfico de la Figura 3. En este se tienen varios elementos que son innecesarios, por ejemplo, el hecho de que sea en 3 dimensiones, que cada barra tenga un color diferente, las leyendas, las líneas del fondo, la textura del fondo, etc. Es interesante ver qué elementos se pueden quitar de este gráfico para llegar al de la Figura 2, el cual es mucho más simple y adecuado.




Figura 3. Ejemplo del uso desacertado de elementos en una visualización

Fuente: elaboración propia

Priorizar la funcionalidad sobre la estética

Priorizar la funcionalidad sobre la estética en la visualización de datos implica centrarse en garantizar que la representación visual cumpla de manera efectiva su propósito informativo antes de considerar aspectos estéticos. Este principio enfatiza la claridad y comprensión de la información presentada, priorizando la transmisión precisa de mensajes sobre elementos decorativos. Es esencial que la visualización sea intuitiva y fácil de interpretar, incluso si esto significa optar por un diseño más simple. Al hacerlo, se asegura que los usuarios puedan extraer información valiosa de manera eficiente, sin distracciones visuales innecesarias. La estética puede ser un complemento, pero no debe comprometer la legibilidad y utilidad de la visualización en términos de comunicación efectiva de

datos. Este principio va de la mano con el de mantenerlo simple, y se puede considerar como ejemplo la Figura 3, en el que se tienen varios aspectos innecesarios como bordes, tridimensionalidad, texturas de fondo, variedad de colores, entre otros (Wilke, 2019).

Evitar sesgos

Evitar sesgos es otro aspecto fundamental. Representar los datos de manera imparcial y evitar distorsiones en la percepción es esencial (Wilke, 2019). Por ejemplo, utilizar escalas adecuadas en un gráfico de barras, evita exagerar diferencias entre categorías y garantiza una representación justa. Como ejemplo de esto, la Figura 4 muestra un gráfico de barras que representa los ingresos en cinco condados de Hawái. El gráfico de la izquierda sugiere disparidades significativas entre los condados, especialmente entre Hawái y Honolulu. Sin embargo, se revela que el gráfico es engañoso, ya que todas las barras comienzan en \$50.000 y la altura de la barra representa cuánto superan los ingresos esa cifra arbitraria. La percepción humana se centra en la altura de la barra, no en la ubicación real de la barra en relación con el eje y. Por otro lado, la gráfica corregida (derecha), en la que la base de cada barra inicia en 0, muestra que, aunque existen diferencias en los ingresos entre los condados, no son tan pronunciadas como sugiere el gráfico inicial. En este ejemplo, se destaca la necesidad de evitar interpretaciones erróneas al considerar la escala y la representación precisa de los datos en las visualizaciones, enfatizando la comparabilidad más realista de los ingresos entre los diferentes condados.




Figura 4. Uso desacertado (izquierda) y acertado (derecha) de las escalas en un gráfico

Fuente: Wilke (2019)

Facilitar comparaciones

La facilitación de comparaciones es un objetivo clave en el diseño de visualizaciones. Utilizar gráficos consistentes permite comparaciones visuales más efectivas. Mantener la escala uniforme en un

gráfico de líneas que compara el rendimiento de diferentes productos a lo largo del tiempo es un ejemplo práctico de este principio.

Etiquetar apropiadamente

Etiquetar apropiadamente contribuye a una comprensión más clara. Proporcionar etiquetas claras en ejes y unidades evita malinterpretaciones. Por ejemplo, en un gráfico de dispersión, etiquetar adecuadamente los ejes garantiza que los observadores comprendan completamente la relación entre las variables representadas.

Usar colores efectivamente

El color es un atributo visual al que en ocasiones se le conoce como **preatentivo**, ya que tiene un impacto inmediato en el observador, llamando la atención de manera rápida. Al iniciar el diseño de una visualización, es recomendable planificarla inicialmente en blanco y negro para comprender mejor cómo el color puede aprovecharse para resaltar elementos específicos o destacar objetos. En una representación que utiliza colores para indicar regiones geográficas, como en la Figura 5, el color de los círculos facilita la asociación con sus respectivas regiones (Caribe, Centro Oriente, Centro Sur, Eje Cafetero, Llano y Pacífico).



[Atributos preatentivos]

Son características de estímulos visuales que captan la atención de manera automática e inconsciente. Estos atributos actúan como señales visuales que destacan ciertos elementos en el entorno visual antes de que la persona sea plenamente consciente de ellos.




Figura 5. Aplicación del color para jerarquizar u organizar objetos

Fuente: elaboración propia

Además, el color puede ser empleado para expresar valores, como se ilustra en la Figura 6, donde diferentes tonos del mismo color indican variaciones en los valores representados por las barras, claro está, además del tamaño de estas.




Figura 6. Aplicación del color para expresar valor

Fuente: elaboración propia

Aunque el color desempeña un papel muy importante en la representación gráfica, es importante evitar el exceso de colores o elecciones inapropiadas, ya que esto podría dificultar la percepción y funcionalidad de la visualización. La Figura 7 muestra cómo una selección inadecuada de colores puede requerir un esfuerzo adicional para distinguir estados en un mapa, destacando la importancia de elegir colores que contrasten adecuadamente para una mejor comprensión.




Figura 7. Ejemplo de uso desacertado (izquierda) y acertado (derecha) del color

Fuente: elaboración propia

Adaptarse al medio y a la audiencia

Este principio en la visualización de datos se refiere a la importancia de ajustar el diseño de las representaciones visuales según el contexto en el que se presentarán y la audiencia a la que se dirigen. Plantea que diferentes entornos y públicos tienen necesidades y expectativas distintas, por lo que la visualización debe ser adaptable para ser efectiva. Por ejemplo, una visualización para un informe interno puede permitirse mayor complejidad y detalle técnico, mientras que una presentación pública o externa a la organización podría requerir una versión más simplificada y accesible para un

entendimiento general. Este principio destaca la necesidad de considerar factores como el nivel de conocimiento de la audiencia, el formato de presentación y el propósito específico de la visualización para optimizar su impacto y utilidad.

Validar la efectividad

Este principio se refiere a la importancia de someter las representaciones visuales a pruebas y evaluaciones con usuarios reales para garantizar su comprensión y utilidad. Este enfoque reconoce que la percepción y la interpretación de una visualización pueden variar entre diferentes individuos, por lo que es esencial recopilar retroalimentación directa. La validación implica someter la visualización a pruebas de usabilidad, donde los usuarios interactúan con la representación de datos y proporcionan comentarios sobre su facilidad de comprensión, claridad y utilidad. Este proceso iterativo de validación contribuye a ajustar y mejorar la visualización, asegurando que sea efectiva y cumpla con sus objetivos comunicativos de manera óptima.

Contextualizar la información

El principio de contextualizar la información en la visualización destaca la importancia de proporcionar información adicional que enriquezca la comprensión y significado de los datos presentados.

Contextualizar implica agregar elementos explicativos, anotaciones o referencias que ayuden a los espectadores a interpretar la información de manera más profunda. Por ejemplo, en una visualización de tendencias de ventas, se podrían añadir anotaciones para resaltar eventos clave, cambios en la estrategia de *marketing* o factores externos que hayan afectado los resultados. Esta práctica asegura que los datos estén conectados con el contexto más amplio en el que se producen, proporcionando a la audiencia una visión más completa y facilitando la toma de decisiones informadas.

5. Conclusiones

El análisis y la visualización de datos desempeñan un papel central en la era de la información, con aplicaciones en prácticamente todas las disciplinas. Existe una amplia diversidad de tipos de datos, desde cifras cuantitativas hasta material multimedia y textual, cada uno con utilidad en campos específicos.

Asimismo, se dispone de una gran variedad de herramientas para la manipulación, el procesamiento y el análisis de estos datos, incluyendo lenguajes de programación, bases de datos, plataformas de

inteligencia de negocios y tecnologías de *big data*, entre otras. La selección de estas herramientas depende en gran medida del dominio de aplicación y de los requerimientos analíticos.

Por otro lado, en la comunicación efectiva de información relevante, la visualización de datos desempeña un papel protagónico, por lo que el dominio de los principios de diseño en este campo es absolutamente necesario. Aspectos como enfocarse en lo importante, mantener la simplicidad, evitar sesgos y validar la efectividad son clave para crear representaciones visuales útiles y comprensibles.

En conclusión, esta unidad ofrece una introducción a conceptos transversales en el trabajo analítico con datos, resaltando tanto la diversidad de tipos de información y herramientas, como la importancia del diseño efectivo de visualizaciones. Estas bases son esenciales para sacar el máximo provecho a los datos en cualquier disciplina.

Referencias

- Alonso Cifuentes, J. C. (2022). *Empezando a transformar bases de datos con R y dplyr*. Editorial Universidad Icesi. <https://doi.org/10.18046/EUI/bda.h.2>
- Ministerio de Tecnologías de la Información y las Comunicaciones [MINTIC]. (2018). *Herramientas de analítica para la explotación de datos*. Ministerio de Tecnologías de la Información y las Comunicaciones. https://herramientas.datos.gov.co/sites/default/files/2020-11/Inventario%20herramientas%20anal%C3%ADtica_0.pdf
- Wilke, C. O. (2019). *Fundamentals of Data Visualization*. O'Reilly Media, Inc. <https://clauswilke.com/dataviz/>



Información técnica

Módulo: Análisis y Visualización de Datos

Unidad 2: Análisis de datos y visualización

Autor: David Bacca Morales

Asesora Pedagógica: Jessica Katherin Pinzón Arias

Diseñador Gráfico: Laura Daniela Ortiz

*Este material pertenece al Politécnico Grancolombiano.
Prohibida su reproducción total o parcial.*